AI agent — hozirgi holat, xarajat va model tanlovi

Sahiy support AI agenti · hisobot sanasi: 2026-10-13 · manba: kod (`support/`, `main.go`), `docs/` va jonli Postgres bazasi

0. Qisqa xulosa

> **1.** Agent texnik jihatdan to'liq ishlaydi: 7 promtli zanjir, OCR, Telegram integratsiyasi, muammoli buyurtmalarni kuzatish, admin panel. Bazada 46 kunlik ish tarixi bor — **17 355 murojaat**, **5 904 suhbat**, **5 884 mijoz**.
>
> **2.** Lekin **ayni hozir to'liq rejim o'chirilgan**: `agent_enabled = false` va `staff_only = true`. Ya'ni agent o'zi mijozga yozmaydi — faqat xodimning guruhdagi javobini mijoz tiliga o'girib beradi.
>
> **3.** Xarajat juda kichik: bitta murojaat **$0,00076**, hozirgi hajmda oyiga **≈$10–11**. Jami 46 kunda $10,84 sarflangan.
>
> **4.** Model tanlashda tejash maqsadi ma'nosiz (oyiga $10 bu xarajat emas). Model **sifat va JSON ishonchliligi** bo'yicha tanlanishi kerak. Asosiy tavsiya: **Claude Haiku 5.5** (sifat yuqori, prompt caching bilan hozirgidan ham arzon) yoki hozirgi **gpt-oss-120b** da qolish.

1. Agent hozir nima qiladi

1.1. Umumiy oqim

```
Mijoz xabari (support chat)
      │
      ▼  poller — har 30 sek (yoki POST /api/agent/run)
 CLIENT_QUIET_SEC=20 → mijoz yozib tugatganini kutadi
      │
      ▼
 promt #1 (yo'naltirish) ──► LLM ──► JSON
      │                              ├── dashboard: true → yetkazma ma'lumoti olinadi
      │                              ├── adminka: true  → Xitoy tomoni buyurtmalari olinadi
      │                              ├── chat  → mijozga javob
      │                              ├── help  → xodimlar guruhiga (Telegram)
      │                              └── promt → keyingi promt id (0/null → tugadi)
      ▼
 keyingi promt (eng ko'pi AGENT_MAX_STEPS = 10 bosqich)
      │
      ├── help → Telegram guruhga DARHOL ketadi (tasdiq kutmaydi)
      └── chat → auto_reply yoqiq → mijozga darhol; o'chiq → tasdiqlash navbatiga
                          │
                          ▼
            javob yetib borsa → xabarlar "o'qilgan" deb belgilanadi
                              → suhbat "hal qilindi" ga o'tadi (auto_resolve)
```

1.2. Promt zanjiri (bazada, paneldan tahrirlanadi)

#	Promt	Hajmi
1	Asosiy — yo'naltirish (router)	3 482 belgi

2	Muammoli holatlar	2 730
3	Javob yozish (tizim ma'lumoti bo'yicha)	4 387
4	Yetkazib berish tarifi	2 272
5	Xodim javobini mijozga yetkazish	3 576
6	Taqiqlangan tovarlar	2 519
7	Qayta buyurtma qilish	2 723

Muhim chegara: **kod ko'rsatma bermaydi, faqat ma'lumot beradi** (JSON, bayroqlar, raqamlar). Qanday yozish — ohang, til, taqiqlar — faqat bazadagi promtda. Shu sababli yangi bayroq qo'shilsa, promt matniga ham qo'shish shart.

1.3. Agent nimalarni o'zi qiladi

Imkoniyat	Nima qiladi
Mijozga javob yozish	Buyurtma holati, yetkazma, tarif, taqiqlangan tovar bo'yicha mijoz tilida javob tayyorlaydi
Til aniqlash	Lotin / o'zbek kirill / rus — til mijozga biriktiriladi, paneldan qo'lda o'zgartirish ham mumkin
Salomlashish	Bir mijozga kunda bir marta, javob matni tilida. Yuborish oldidan kod hakamlik qiladi — ikki marta salom ketmaydi
Xayrlashish	"rahmat", "hop" kabi xabarlarga modelsiz, tayyor matn bilan javob (token sarflanmaydi)
Rasmdan raqam o'qish	tesseract OCR — buyurtma/trek raqamini rasmdan o'qiydi. Rasm modelga umuman yuborilmaydi (bepul, ~0,1 sek). Bugungacha 694 marta muvaffaqiyatli, 317 marta raqam topilmagan
Tizimdan ma'lumot olish	Yetkazma (delivery) va adminka (daigou) API'laridan buyurtma holati olinadi, saralanadi, faqat kerakli maydonlar modelga beriladi
Viloyat mantiqi	Uyga yetkazish faqat Toshkent shahri va viloyatida — qolgan viloyatlarda filialdan olib ketish. Model taxmin qilmaydi, kod tayyor matn beradi
Muammoli buyurtmalar	Statuslar 3, 4, 12 kuzatiladi; har biriga alohida kun chegarasi (3:3, 4:7, 12:3). Guruhga chiqadi, bazada kuzatiladi. Bugungacha **1 690** muammo ochilgan, **1 518** hal qilingan, **172** ochiq
Telegram guruh	`help` matni guruhga ketadi; xodim reply qilsa, uning javobi 5-promt orqali mijoz tiliga o'girib yuboriladi (bugungacha 669 marta)
Kunlik hisobot	Statistika, mijozlar kesimi, muammolar kesimi — `/api/stats/*`
Admin panel	Dashboard, Navbat (tasdiqlash), Promtlar, Muammolar, Sozlamalar, Detallar — React (Vite)

1.4. Jonli sozlamalar (bazadagi `settings` jadvali)

Sozlama	Qiymat	Ma'nosi
`agent_enabled`	false	**Agent o'chirilgan** — zanjir yurmaydi, token sarflanmaydi

`staff_only`	true	**Faqat mutaxassis javoblari rejimi** — AI suhbatga o'zi kirmaydi, faqat xodim javobini tarjima/moslashtiradi
`ai_provider`	groq	Faol provayder
`auto_reply`	true	Chat javobi tasdiqsiz ketadi
`auto_resolve`	true	Javobdan keyin suhbat yopiladi
`help_to_telegram`	true	help guruhga ketadi
`greeting_enabled`	true	Kunda bir marta salom
`poll_enabled`	true	Fon sikli yoqilgan
`poll_interval_sec`	30	Sikl oralig'i
`batch_size`	30	Bir siklda eng ko'p suhbat
`chat_delay_sec`	5	Suhbatlar orasidagi tanaffus

Diqqat. Hozirgi holatda agent **to'liq avtonom ishlamayapti**. `agent_enabled=false` + `staff_only=true` — bu "AI o'zi mijozga yozmaydi" degani. Agentni to'liq yoqish uchun panelda ikkalasini ham o'zgartirish kerak: `agent_enabled=true`, `staff_only=false`. O'zgarish darhol kuchga kiradi, qayta ishga tushirish shart emas.

2. Ish hajmi — bazadagi haqiqiy raqamlar

Davr: 2026-08-29 … 2026-10-13 (46 kalendar kun, shundan 37 kunda faol ish bo'lgan).

17 355	5 904	5 884	$10,84
MUROJAAT	SUHBAT	MIJOZ	JAMI XARAJAT

Ko'rsatkich	Qiymat
Chat javobi tayyorlangan murojaat	17 048
Xodimga topshirilgan (`help` matni bo'lgan)	3 857
Telegram guruhga yetib borgan help	3 752
Mijozga yuborilgan javob (status `sent`)	6 858
Panelda tasdiqlangan (`approved`)	2 336
Rad etilgan (`rejected`)	7 857
Xato bilan tugagan (`failed`)	299
Xodim javobini tarjima qilish (`source = telegram`)	669
O'rtacha bosqich soni (zanjir uzunligi)	1,83
O'rtacha LLM chaqiruvi (bitta murojaatga)	1,72
Faol kundagi o'rtacha murojaat	469

> **Diqqat qilinadigan raqam: 7 857 rad etilgan javob (45%).** Bu tayyorlangan javoblarning deyarli yarmi panelda rad etilgani — tokeni sarflangan, lekin ishga ketmagan. Bu xarajat emas (jami bir necha dollar), lekin **sifat ko'rsatkichi**: nega rad etilayotgani promtlar kesimida tahlil qilinsa, agentni to'liq yoqishdan oldingi eng muhim ish shu bo'ladi.

3. O'rtacha xarajatlar

3.1. Bitta murojaatning tarkibi

Model	Murojaat	O'rt. kirish	O'rt. chiqish	O'rt. narx	Jami
`openai/gpt-oss-120b` (Groq)	14 270	3 773	323	$0,00076	$10,84
`deepseek-flash`	2 696	3 782	1 309	$0,00000 *	$0,00 *
Model yozilmagan / xato	389	0	0	—	—

* `DEEPSEEK_PRICE_IN` / `DEEPSEEK_PRICE_OUT` `.env` da berilmagan, shuning uchun kod narxni 0 deb yozadi. DeepSeek bilan ishlangan 2 696 murojaatning haqiqiy qiymati taxminan **$3,6** (off-peak tarifda) — paneldagi jami xarajat shu qadar kam ko'rsatilgan.

3.2. O'rtacha xarajat — asosiy raqamlar

Birlik	Groq (hozirgi)
1 murojaat	$0,00076
1 000 murojaat	$0,76
1 faol kun (≈469 murojaat)	$0,36
1 oy (hozirgi hajm, ≈14 000 murojaat)	$10,7
1 oy (hajm 2× oshsa, 28 000)	$21,3
1 oy (hajm 5× oshsa, 70 000)	$53,2

Narx tarkibi: **kirish tokeni 74%**, chiqish tokeni 26%. Ya'ni asosiy pul javobga emas, **promt + tarix + tizim ma'lumotiga** ketadi. O'rtacha kirish 3 773 token — bu 7 promtdan biri, oxirgi 10 xabar va saralangan buyurtma JSON'i.

3.3. Xarajatni kamaytirishning eng kuchli yo'li — prompt caching

Kirish 74% ni yeyayotgani uchun eng katta ta'sir modelni almashtirishda emas, **keshda**. Promt prefiksi barqaror yig'iladi (`mapJSON` kalitlarni tartiblaydi), ya'ni kesh uchun asos bor. Lekin hozir `cached_tokens` **doim 0** — provayder bu raqamni qaytarmaydi va kodda hech kim to'ldirmaydi.

- **Groq:** keshlangan kirish ~50% arzon ($0,075/1M) → murojaat $0,00076 → **$0,00055**
- **DeepSeek:** kesh hit $0,003/1M — kirishda 50 baravar arzon
- **Anthropic (Haiku 5.5):** kesh o'qish 0,1× ($0,01/1M) → murojaat **$0,00027** (hozirgidan 2,8× arzon)

Nozik joy: har promtga bugungi sana qo'shiladi, ya'ni kesh har yarim tunda bir marta bekor bo'ladi. Bu ma'lum va qabul qilingan.

4. Qaysi modelga o'tish mumkin

4.1. Yagona texnik shart

Kod modeldan `response_format: {"type":"json_object"}` ni talab qiladi (`support/groq.go:139` , `support/deepseek.go:100`). Butun qaror yo'li JSON'ga tayanadi. Shuning uchun model **JSON rejimini qo'llashi shart**. Yaxshi xabar: `json_schema` emas, oddiy `json_object` yetarli — ya'ni tanlov eski hujjatda yozilganidan ancha keng.

Ikkinchi texnik shart: provayder **OpenAI-mos** `/chat/completions` endpointini bersin — unda `GROQ_BASE_URL` + `GROQ_MODEL` ni o'zgartirish bilan kifoyalanadi, kod yozilmaydi. Anthropic va Google boshqa API shaklida ishlaydi — ularga o'tish uchun `support/` ga yangi klient fayli kerak (mavjud `LLM` interfeysi bu uchun allaqachon tayyor: `Ready()` va `Generate()` — ~100 qator kod).

4.2. Taqqoslash — bizning haqiqiy token profilimizda (3 773 kirish / 323 chiqish)

Model	Kirish $/1M	Chiqish $/1M	1 murojaat	Oyiga*	Integratsiya
Claude Haiku 5.5 + kesh	0,10	0,50	**$0,00027**	**$3,8**	Yangi klient (~100 qator)
Gemini 2.5 Flash-Lite	0,10	0,40	$0,00051	$7,2	Yangi klient
Claude Haiku 5.5 (keshsiz)	0,10	0,50	$0,00054	$7,5	Yangi klient
Groq + kesh (hozirgi model)	0,075	0,60	$0,00055	$7,7	O'zgarish yo'q
gpt-oss-120b (Groq) — HOZIRGI	0,15	0,60	**$0,00076**	**$10,7**	—
Gemini 3.1 Flash-Lite	0,25	1,00	$0,00126	$17,6	Yangi klient
deepseek-flash (off-peak)	0,15	0,60	$0,00135 **	$18,9	Tayyor — `ai_provider`
GPT-5 mini	0,25	2,00	$0,00159	$22,2	OpenAI-mos — faqat .env
deepseek-flash (peak)	0,30	1,20	$0,00270 **	$37,8	Tayyor
Gemini 3 Flash	0,50	3,00	$0,00286	$40,0	Yangi klient
Claude Sonnet 5.5	2,00	10,00	$0,01078	$151	Yangi klient

* Hozirgi hajmda — oyiga ≈14 000 murojaat.
** DeepSeek uchun o'zining **haqiqiy** o'rtacha chiqishi ishlatilgan: 1 309 token, ya'ni gpt-oss'dan 4 baravar ko'p gapiradi. Shuning uchun "bir xil narx" bo'lsa ham amalda qimmatroq chiqadi — bu bazadagi 2 696 murojaatdan olingan o'lchov, taxmin emas.
Narxlar ochiq manbalardan olingan va o'zgarishi mumkin — pul ajratishdan oldin provayderning o'z sahifasidan tekshirish kerak.

4.3. Tavsiya

> **Asosiy xulosa: xarajat sababli model almashtirish kerak emas.** Oyiga $10 — bu qaror qabul qilish uchun sabab bo'lmaydigan summa. Modelni faqat **sifat** yoki **ishonchlilik** uchun almashtirish ma'noga ega.
>
> **1-variant — hozirgi holatda qolish (eng xavfsiz).** `gpt-oss-120b` JSON bilan ishlaydi, 46 kunda sinovdan o'tgan, xarajati arzon. Buning ustiga Groq keshini yoqish — bepul 30% tejash.

> **2-variant — Claude Haiku 4.5 (sifat uchun eng kuchli tanlov).** $0,10/$0,50 — hozirgidan arzon, prompt caching bilan 2,8× arzon; o'zbek/rus tilida va ko'rsatmaga amal qilishda gpt-oss'dan sezilarli ustun. Narxi: `support/` ga bitta yangi klient fayli (`LLM` interfeysi allaqachon shu uchun qilingan).
>
> **3-variant — DeepSeek'ni asosiy qilish: tavsiya etilmaydi.** Kodda tayyor va paneldan bir tugma bilan almashadi, lekin o'lchovga ko'ra 4× uzun javob yozadi, ya'ni ikki baravar qimmat va javoblar cho'zilib ketadi. Zaxira sifatida qolsin.
>
> **Qaysi holatda ham birinchi qilinadigan ish model emas:** 45% rad etilgan javob sababini tahlil qilish. Model almashtirish bu raqamni o'zi tuzatmaydi — promtlar tuzatadi.

5. Texnik qarzlar (hisobotdan chiqqan)

Joy	Muammo
`docs/model-va-cache.md`	**Hujjat eskirgan.** Unda lokal Ollama (`llama3.1:8b`) asosiy model, Groq zaxira deb yozilgan va `internal/...` yo'llari ko'rsatilgan. Kodda bunday narsa yo'q: `support/llm.go` da faqat Groq va DeepSeek bor, Ollama butunlay olib tashlangan. Hujjatni yangilash kerak, aks holda keyingi qarorlar noto'g'ri asosda olinadi.
`.env`	`DEEPSEEK_PRICE_IN/OUT` berilmagan → DeepSeek bilan ishlangan 2 696 murojaat xarajati panelda $0 ko'rinadi (haqiqatda ≈$3,6).
`cached_tokens`	Baza ustuni, narx hisobi va dashboard ustuni bor, lekin hech kim to'ldirmaydi — doim 0. Keshdan tejash o'lchanmayapti.
`AGENT_MAX_STEPS`	`.env` da 10, hujjatda 5 deb yozilgan. Amalda o'rtacha 1,83 bosqich ishlatilmoqda, ya'ni chegara hech qachon urilmaydi — lekin nomuvofiqlik qoldi.
`order_issues.reason`	1 690 yozuvning hammasida bo'sh — ustun qo'shilgan, lekin to'ldirilmaydi. Muammolarni sabab kesimida tahlil qilish imkoni yo'q.

Hisobot Claude Code tomonidan loyiha kodi va jonli bazasidan avtomatik yig'ilgan · 2026-10-13 · raqamlar manbasi: `interactions`, `order_issues`, `promts`, `settings` jadvallari